

Федеральное государственное автономное образовательное учреждение высшего образования

«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Отчёт по расчётно-графической работе №1

Математическая статистика

Вариант А-5

Выполнил: Караганов Павел

Группа: Р3210

Проверил: Брыксина Екатерина Сергеевна

г. Санкт-Петербург,

2026

Сведения о варианте

- Идентификатор варианта: А-5
- Объём выборки: $n = 200$

1. Первичное описание выборки

Для каждого столбца X_1, X_2, X_3 были построены вариационные ряды, эмпирические функции распределения (ЭФР) и гистограммы с использованием правил Стерджеса и Скотта.

1.1 Вариационный ряд и эмпирическая функция распределения

Пусть наблюдения упорядочены по возрастанию:

$$x_1 \leq x_2 \leq \dots \leq x_n.$$

Эмпирическая функция распределения задаётся как

$$F_{n(x)} = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x).$$

1.2 Правила построения гистограммы

Обозначим размах выборки через

$$R = x_n - x_1.$$

Если k — число интервалов, а h — ширина интервала, то

$$h = \frac{R}{k}.$$

Правило Стерджеса: сначала выбирается число интервалов

$$k_{\text{St}} = 1 + \lfloor \log_2 n \rfloor,$$

затем

$$h_{\text{St}} = \frac{R}{k_{\text{St}}}.$$

Для нашей выборки $n = 200$:

$$k_{\text{St}} = 1 + \lfloor \log_2 200 \rfloor = 1 + 7 = 8.$$

Правило Скотта: сначала выбирается ширина интервала

$$h_{\text{Sc}} = 3.5 S n^{-\frac{1}{3}},$$

после чего

$$k_{\text{Sc}} = \left\lceil \frac{R}{h_{\text{Sc}}} \right\rceil.$$

Для плотностной гистограммы высота столбца для j -го интервала с частотой n_j :

$$f_j = \frac{n_j}{nh}.$$

Такая нормировка обеспечивает суммарную площадь столбцов, близкую к 1.

1.3 Ключевые выборочные характеристики

Используются следующие оценки:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad S = \sqrt{S^2}, \quad \hat{\sigma} = \sqrt{\hat{\sigma}^2}.$$

Обоснование по форме распределений:

- Для X_1 наблюдается сильная правосторонняя асимметрия и выраженная нижняя граница, что согласуется с моделью сдвинутого экспоненциального распределения $\text{Exp}_{\lambda,c}$.
- Для X_2 гистограмма близка к плоской на ограниченном интервале, а ЭФР примерно линейна в центральной части; это согласуется с равномерной моделью $U(a, b)$.
- Для X_3 гистограмма имеет колоколообразную форму, ЭФР — S-образную, а $\bar{x}$ близко к m_e , что типично для нормальной модели $N(a, \sigma)$.

Числовые характеристики:

Столбец	$\bar{x}$	S^2	S	$\hat{\sigma}^2$	$\hat{\sigma}$	m_e	Q_1	Q_3
X_1	115.9398	10866.0997	104.2406	10920.7032	104.5022	75.9150	42.2275	148.2675
X_2	51.8794	266.3561	16.3204	267.6946	16.3614	53.6300	37.0650	64.6250
X_3	67.6959	56.5674	7.5211	56.8516	7.5400	67.9800	62.3575	72.9825

Анализ формы (по графикам ниже):

- X_1 : Присутствует сильная асимметрия, имеется длинный правый «хвост» (выбросы). Естественная нижняя граница явно выражена.
- X_2 : Гистограмма имеет форму, близкую к прямоугольной, без явных выбросов. Выборочное среднее и медиана близки.
- X_3 : Симметричная колоколообразная форма распределения, среднее почти совпадает с медианой.

Графики для X_1




Рис. 1. Рис. 1. Сравнение правил разбиения гистограммы для X_1




Рис. 2. Рис. 2. Вариационный ряд и эмпирическая/теоретическая функция распределения для X_1

Графики для X_2




Рис. 3. Рис. 3. Сравнение правил разбиения гистограммы для X_2




Рис. 4. Рис. 4. Вариационный ряд и эмпирическая/теоретическая функция распределения для X_2

Графики для X_3




Рис. 5. Рис. 5. Сравнение правил разбиения гистограммы для X_3




Рис. 6. Рис. 6. Вариационный ряд и эмпирическая/теоретическая функция распределения для X_3

2. Предположение о виде закона распределения

Основываясь на визуальном анализе и рассчитанных характеристиках, выдвинуты следующие гипотезы:

1. $X_1 \sim \text{Exp}_{\lambda, c}$. Обоснование: наличие жёсткой левой границы, длинного правого хвоста и сильное расхождение между средним и медианой характерно для экспоненциального распределения.
2. $X_2 \sim U(a, b)$. Обоснование: гистограмма имеет плоскую вершину, частоты попадания в интервалы примерно равны, отсутствие длинных хвостов.
3. $X_3 \sim N(a, \sigma)$. Обоснование: симметрия относительно математического ожидания, визуальное соответствие форме кривой Гаусса (колокол).

3. Оценивание параметров

3.1 Экспоненциальное распределение ($X_1 \sim \text{Exp}_{\lambda, c}$)

Метод моментов (ММ): Приравниваем теоретические моменты выборочным:

$$E(X) = c + \frac{1}{\lambda} = \bar{x}, \quad D(X) = \frac{1}{\lambda^2} = S^2.$$

Отсюда

$$\hat{\lambda}_{\text{ММ}} = \frac{1}{\bar{S}} = 0.0096,$$

$$\hat{c}_{\text{ММ}} = \bar{x} - \frac{1}{\hat{\lambda}_{\text{ММ}}} = 11.6992.$$

Метод максимального правдоподобия (ММП): Плотность модели:

$$f(x | \lambda, c) = \lambda \exp(-\lambda(x - c))I(x \geq c).$$

Функция правдоподобия:

$$L(\lambda, c) = \prod_{i=1}^n \lambda \exp(-\lambda(x_i - c))I(x_i \geq c).$$

Логарифм правдоподобия:

$$\ln L(\lambda, c) = n \ln \lambda - \lambda \sum_{i=1}^n (x_i - c),$$

$$c \leq \min x_i.$$

Максимум по c достигается на границе допустимых значений:

$$\hat{c}_{ML} = \min x_i = 19.9700.$$

После подстановки в $\ln L$ и максимизации по λ :

$$\hat{\lambda}_{ML} = \frac{1}{\bar{x} - \hat{c}_{ML}} = 0.0104.$$




Рис. 7. Рис. 8. X_1 : сравнение плотностей при оценках ММ и ММП

3.2 Равномерное распределение ($X_2 \sim U(a, b)$)

Метод моментов (ММ): Теоретические моменты:

$$E(X) = \frac{a+b}{2}, \quad D(X) = \frac{(b-a)^2}{12}.$$

Система уравнений ММ:

$$\frac{a+b}{2} = \bar{x}, \quad \frac{(b-a)^2}{12} = S^2.$$

Решение:

$$\hat{a}_{MM} = \bar{x} - \sqrt{3S^2} = 23.6116,$$

$$\hat{b}_{MM} = \bar{x} + \sqrt{3S^2} = 80.1472.$$

Метод максимального правдоподобия (ММП): Плотность:

$$f(x|a, b) = \frac{1}{b-a}I(a \leq x \leq b).$$

Правдоподобие:

$$L(a, b) = \left(\frac{1}{b-a}\right)^n \prod_{i=1}^n I(a \leq x_i \leq b).$$

Чтобы $L(a, b)$ было ненулевым, интервал $[a, b]$ должен покрывать всю выборку. При этом $L(a, b)$ тем больше, чем меньше длина $(b - a)$, поэтому максимум достигается на минимальном покрывающем интервале:

$$\hat{a}_{\text{ML}} = \min x_i = 24.9900,$$

$$\hat{b}_{\text{ML}} = \max x_i = 79.8500.$$




Рис. 8. Рис. 9. X_2 : сравнение плотностей при оценках ММ и ММП

3.3 Нормальное распределение ($X_3 \sim N(a, \sigma^2)$)

Метод моментов (ММ): Для нормального закона:

$$E(X) = a, \quad D(X) = \sigma^2.$$

Приравнявая к выборочным моментам, получаем:

$$\hat{a}_{\text{MM}} = \bar{x} = 67.6959,$$

$$\hat{\sigma}_{\text{MM}}^2 = S^2 = 56.5674.$$

Метод максимального правдоподобия (ММП): Логарифмическая функция правдоподобия:

$$\ln L(a, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2.$$

Условия максимума дают:

$$\hat{a}_{\text{ML}} = \bar{x},$$

$$\hat{\sigma}_{\text{ML}}^2 = S^2.$$

Численно:

$$\hat{a}_{\text{ML}} = 67.6959,$$

$$\hat{\sigma}_{\text{ML}}^2 = 56.5674.$$




Рис. 9. Рис. 10. X_3 : сравнение плотностей при оценках ММ и ММП

3.4 Сравнение ММ и ММП

- Для X_1 : $\hat{c}_{ML} > \hat{c}_{MM}$, а $\hat{\lambda}_{ML}$ немного больше; это связано с тем, что ММП использует минимум выборки.
- Для X_2 : ММП определяется крайними наблюдениями ($\min x_i, \max x_i$), тогда как ММ использует среднее и дисперсию всей выборки.
- Для X_3 : оценки ММ и ММП совпадают, что типично для нормальной модели при таких параметрах.

4. Оценивание параметрической вероятности

В качестве порога для каждого столбца используется

$$x_0 = \bar{x} + \hat{\sigma}.$$

4.1 Эмпирическая оценка вероятности

Эмпирическая оценка строится по доле наблюдений выше порога:

$$\hat{P}_{\text{emp}}(X > x_0) = \frac{1}{n} \sum_{i=1}^n I(x_i > x_0).$$

Численные значения:

- Для X_1 : $x_0 = 220.4420$, $\hat{P}_{\text{emp}} = 0.1500$.
- Для X_2 : $x_0 = 68.2408$, $\hat{P}_{\text{emp}} = 0.2000$.
- Для X_3 : $x_0 = 75.2359$, $\hat{P}_{\text{emp}} = 0.1750$.

4.2 Параметрическая оценка вероятности

В параметрическом подходе в теоретическую формулу подставляются оценки параметров ММП.

Для $X_1 \sim \text{Exp}_{\lambda, c}$:

$$P(X > x_0) = \exp(-\lambda(x_0 - c)), \quad x_0 \geq c.$$

После подстановки $\hat{\lambda} = 0.0104$, $\hat{c} = 19.9700$, $x_0 = 220.4420$:

$$\hat{P}_{\text{param}} = \exp(-0.0104(220.4420 - 19.9700)) = 0.1238.$$

Для $X_2 \sim U(a, b)$:

$$P(X > x_0) = \frac{b-x_0}{b-a}, \quad a \leq x_0 \leq b.$$

После подстановки $\hat{a} = 24.9900$, $\hat{b} = 79.8500$, $x_0 = 68.2408$:

$$\hat{P}_{\text{param}} = \frac{79.8500-68.2408}{79.8500-24.9900} = 0.2116.$$

Для $X_3 \sim N(a, \sigma^2)$:

$$P(X > x_0) = 1 - \Phi\left(\frac{x_0-a}{\sigma}\right).$$

После подстановки $\hat{a} = 67.6959$, $\hat{\sigma} = 7.5211$, $x_0 = 75.2359$:

$$\hat{P}_{\text{param}} = 1 - \Phi\left(\frac{75.2359-67.6959}{7.5211}\right) = 0.1580.$$

4.3 Сопоставление оценок

Столбец	x_0	$\hat{P}_{\text{emp}}$	$\hat{P}_{\text{param}}$
X_1	220.4420	0.1500	0.1238
X_2	68.2408	0.2000	0.2116
X_3	75.2359	0.1750	0.1580

Вывод: значения $\hat{P}_{\text{emp}}$ и $\hat{P}_{\text{param}}$ для всех трёх столбцов близки, что подтверждает согласованность выбранных моделей с данными.

5. Оценка по сгруппированной выборке

5.1 Формулы для сгруппированной выборки

Пусть выборка разбита на m интервалов, n_k — частота в k -м интервале, x_k^* — середина k -го интервала. Тогда оценки моментов имеют вид:

$$\hat{E}_g = \frac{1}{n} \sum_{k=1}^m n_k x_k^*,$$

$$\hat{D}_g = \frac{1}{n-1} \sum_{k=1}^m n_k (x_k^* - \hat{E}_g)^2.$$

5.2 Результаты расчётов

Столбец	$\hat{E}_g$	$\bar{x}$	$\hat{D}_g$	$\hat{\sigma}^2$
X_1	121.7491	115.9398	10096.0511	10920.7032
X_2	52.0428	51.8794	252.7067	267.6946
X_3	67.8426	67.6959	57.6132	56.8516

5.3 Интерпретация

По всем столбцам $\hat{E}_g$ и $\hat{D}_g$ близки к оценкам по исходной выборке. Следовательно, переход к сгруппированным данным приводит к умеренной потере точности, но сохраняет основные характеристики распределений.

6. Доверительные интервалы (уровень доверия 0.95)

6.1 Асимптотический доверительный интервал для $E(X)$

При $\gamma = 1 - \alpha = 0.95$ и $z_{1-\frac{\alpha}{2}} = 1.96$ используем формулу (ЦПТ):

$$E(X) \in \left(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}} \right).$$

Численные интервалы:

- $X_1: E(X) \in (101.4568; 130.4228)$.
- $X_2: E(X) \in (49.6119; 54.1469)$.
- $X_3: E(X) \in (66.6509; 68.7408)$.

6.2 Точные интервалы для нормальной модели ($X_3 \sim N(a, \sigma^2)$)

Для математического ожидания при неизвестной дисперсии:

$$a \in \left(\bar{x} - t_{1-\frac{\alpha}{2}, n-1} \frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + t_{1-\frac{\alpha}{2}, n-1} \frac{\hat{\sigma}}{\sqrt{n}} \right).$$

Для дисперсии:

$$\sigma^2 \in \left((n-1) \frac{\hat{\sigma}^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2}, (n-1) \frac{\hat{\sigma}^2}{\chi_{\frac{\alpha}{2}, n-1}^2} \right).$$

Численные результаты для X_3 :

- Для a : $a \in (66.6445; 68.7472)$.
- Для σ^2 : $\sigma^2 \in (47.1474; 69.9113)$.

6.3 Интерпретация

Доверительный интервал уровня 0.95 означает надёжность процедуры: при многократном повторении эксперимента около 95% построенных интервалов будут накрывать истинное значение параметра. Это не «вероятность параметра», а характеристика метода оценивания.

7. Итоговый вывод

В ходе работы был проведен полный цикл анализа данных. Выборки были идентифицированы как распределения $\text{Exp}(X_1)$, $U(X_2)$ и $N(X_3)$. Вычислены оценки параметров методами ММ и ММП, показана их состоятельность. Доверительные интервалы получились достаточно узкими (благодаря $n = 200$), что говорит о высокой точности полученных точечных оценок. Данные модели можно использовать для предсказаний (например, расчета вероятностей редких событий) в реальных задачах.

Бонус. Анализ столбца X_4 (Бимодальность)

Построенная гистограмма столбца X_4 имеет два ярко выраженных пика. Это свидетельствует о неоднородности данных — скорее всего, выборка представляет собой смесь двух распределений

(режимов работы, типов оборудования и т.д.). С помощью алгоритма k -средних ($k = 2$) выборка была разделена на два кластера:

- Кластер 1: $n = 96, \bar{x} = 54.0238$
- Кластер 2: $n = 104, \bar{x} = 97.8139$

Использование «общего среднего» (76.7947) некорректно, так как оно попадает в провал между двумя пиками, где реальных данных почти нет. Оно не описывает ни одну из подгрупп адекватно.




Рис. 10. Рис. 7. Гистограмма и кластеризация для X_4