

Федеральное государственное автономное образовательное учреждение высшего образования

«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Отчёт по расчётно-графической работе №3

Математическая статистика

Вариант А-5

Выполнил: Караганов Павел

Группа: Р3210

Проверил(а): Брыксина Екатерина Сергеевна

г. Санкт-Петербург,

2026

1. Идентификатор варианта и данные

- **Источник данных:** `openintro::ssd_speed` без дополнительных фильтров.
- **Переменные:** x — Скорость чтения, МБ/с; y — Скорость записи, МБ/с.
- **Число наблюдений:** $n = 54$

2. Диаграмма рассеяния и гипотеза




Рис. 1. Диаграмма рассеяния и графики регрессионных моделей

Гипотеза: Визуальный анализ диаграммы рассеяния позволяет установить наличие выраженной положительной зависимости: с ростом скорости чтения закономерно увеличивается скорость записи. Однако данный рост носит нелинейный характер — при высоких значениях фактора x скорость y возрастает, а также увеличивается дисперсия значений. На основании этого выдвигается гипотеза о том, что степенная или квадратичная модель аппроксимируют исходные данные более адекватно, чем линейная.

3. Построение трёх моделей

1. Линейная модель: Искомый вид уравнения регрессии:

$$\hat{y} = a + bx$$

После оценки параметров методом наименьших квадратов (МНК) получено итоговое уравнение:

$$\hat{y} = -24.3578 + 0.9879x$$

2. Квадратичная модель: Искомый вид уравнения регрессии:

$$\hat{y} = a + bx + cx^2$$

Оценки параметров позволили получить следующее уравнение:

$$\hat{y} = -291.2995 + 1.6032x - 0.000243x^2$$

3. Степенная модель (дополнительная): Искомый вид уравнения регрессии:

$$y = ax^b$$

Для нахождения параметров применяется приведение к линейному виду путем логарифмирования обеих частей:

$$\ln y = \ln a + b \ln x$$

Оценки параметров линейризованной модели составили: $\ln a = -0.3646$, $b = 1.0402$.

Возвращаясь к исходным переменным, получаем итоговое уравнение степенной модели:

$$\hat{y} = 0.6944x^{1.0402}$$

4. Сравнение моделей

Качество построенных моделей оценивается с помощью коэффициента детерминации (R^2), среднеквадратической ошибки (RMSE) и средней ошибки аппроксимации (A).

Модель	R^2	RMSE	Ошибка аппроксим. A , %
Линейная	0.7446	402.8958	18.85
Квадратичная	0.7542	395.2681	18.36
Степенная	0.7401	406.4618	16.74

Вывод: Сравнительный анализ показателей качества моделей свидетельствует о том, что наиболее высокой аппроксимирующей способностью обладает **квадратичная** модель, поскольку для неё характерен наибольший коэффициент детерминации R^2 (0.7542) и наименьшая ошибка RMSE.

5. Подробный статистический анализ линейной модели

5.1 Оценивание коэффициентов методом наименьших квадратов

Линейная регрессионная модель $\hat{y} = a + bx$ оценивается методом наименьших квадратов (МНК). Оценки параметров минимизируют остаточную сумму квадратов $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ и вычисляются по формулам:

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{a} = \bar{y} - \hat{b}\bar{x}$$

Полученные оценки:

- Свободный член: $\hat{a} = -24.3578$
- Коэффициент наклона: $\hat{b} = 0.9879$

Интерпретация: на каждый МБ/с прироста скорости чтения скорость записи увеличивается на 0.9879 МБ/с в среднем.

5.2 Анализ остатков и оценка дисперсии

- **Остаточная сумма квадратов:** $RSS = 8765550.3121$
- **Несмещённая оценка дисперсии ошибки:** $s^2 = \frac{RSS}{n-2} = 168568.2752$
- **Стандартная ошибка регрессии:** $s = \sqrt{168568.2752} = 410.5707$ МБ/с

Эта величина показывает типичное отклонение фактических значений от линии регрессии.

5.3 Доверительные интервалы для коэффициентов ($\alpha = 0.05$)

При уровне значимости $\alpha = 0.05$ и степенях свободы $n = 52$, критическое значение t -распределения: $t_{\text{крит}} = 2.0066$.

95% доверительные интервалы:

- Для свободного члена a : $\hat{a} \pm t_{\text{крит}} \cdot SE(\hat{a}) = (-237.92; 189.20)$
- Для коэффициента наклона b : $\hat{b} \pm t_{\text{крит}} \cdot SE(\hat{b}) = (0.8269; 1.1489)$

Оба интервала не содержат ноль, подтверждая статистическую значимость.

5.4 Проверка гипотезы о значимости коэффициента наклона

- Основная гипотеза: $H_0 : b = 0$ (нет связи)
- Альтернативная гипотеза: $H_1 : b \neq 0$ (есть связь)
- Наблюдаемое значение: $t_{\text{набл}} = \frac{\hat{b}}{SE(\hat{b})} = 12.3131$
- Критическое значение: $t_{\text{крит}} = 2.0066$

Поскольку $|t_{\text{набл}}| = 12.3131 \gg t_{\text{крит}} = 2.0066$, нулевая гипотеза решительно отвергается.

Коэффициент при x статистически значим.

5.5 Коэффициент детерминации

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 0.7446$$

Модель объясняет 74.46% вариации скорости записи. Оставшиеся 25.54% обусловлены неучтёнными факторами.

6. Прогноз

6.1 Точечные прогнозы по трём моделям

При заданном значении $x^* = 1207.9904$ МБ/с подставляем в уравнения:

- **Линейная:** $\hat{y}_{\text{лин}} = -24.3578 + 0.9879 \cdot 1207.9904 = 1169.0354$ МБ/с
- **Квадратичная:** $\hat{y}_{\text{квадр}} = -291.2995 + 1.6032 \cdot 1207.9904 - 0.000243 \cdot (1207.9904)^2 = 1290.6289$ МБ/с
- **Степенная:** $\hat{y}_{\text{степ}} = 1116.0685$ МБ/с

6.2 Интервальное оценивание

95% доверительный интервал для условного среднего при $x^* = 1207.9904$: $\hat{y} \pm t_{\text{крит}} \cdot SE(\hat{y}) \approx (1099; 1239)$ МБ/с

6.3 Выбор модели

На основе анализа раздела 4, выбирается **квадратичная модель** с наивысшим $R^2 = 0.7542$ и наименьшей RMSE. Итоговый прогноз: $\hat{y}_{\text{квадр}} = 1290.6289$ МБ/с.

7. Итоговый вывод

7.1 Основные результаты

В работе исследовалась зависимость скорости записи (y) от скорости чтения (x) на данных `openintro::ssd_speed` ($n = 54$). Построены и оценены три модели регрессии.

Модель	R^2	RMSE	Интерпретация
Линейная	0.7446	402.8958	Базовая, объясняет 74.46%
Квадратичная	0.7542	395.2681	Лучшая, захватывает нелинейность
Степенная	0.7401	406.4618	Дополнительная, худшая из трёх

7.2 Выбор оптимальной модели

Квадратичная модель выбрана как оптимальная благодаря:

- Наивысшему коэффициенту детерминации: $R^2 = 0.7542$
- Минимальной среднеквадратической ошибке: $\text{RMSE} = 395.27$ МБ/с
- Лучшему объяснению нелинейности данных

7.3 Интерпретация результатов

Найденная зависимость свидетельствует о:

- **Сильной положительной связи:** $\hat{b} = 0.9879 \gg 0$, подтвержденной статистически ($t_{\text{набл}} = 12.3131$)
- **Нелинейности при высоких скоростях:** отрицательный коэффициент при x^2 показывает замедление роста скорости записи, вероятно из-за аппаратных ограничений
- **Остаточной вариации 25.54%:** объясняется неучтёнными факторами (тип памяти, температура, архитектура)

8. Исходный код анализа

```
1 import pandas as pd
2 import numpy as np
3
4 # Загрузка данных
5 df = pd.read_csv('data.csv', sep=',')
6 x = df['x'].values
7 y = df['y'].values
8 n = len(x)
9
10 # Линейная регрессия:  $y = a + bx$ 
11 b_lin, a_lin = np.polyfit(x, y, 1)
12 y_pred_lin = a_lin + b_lin * x
13
14 print(f"Линейная модель:  $y = \{a\_lin:.4f\} + \{b\_lin:.4f\}x$ ")
15 print(f"Параметры:  $a = \{a\_lin:.4f\}$ ,  $b = \{b\_lin:.4f\}$ ")
16
```

Таблица 1. Листинг 1: Линейная регрессия

```
1 import numpy as np
2
3 # Квадратичная регрессия:  $y = a + bx + cx^2$ 
4 c_quad, b_quad, a_quad = np.polyfit(x, y, 2)
5 y_pred_quad = a_quad + b_quad * x + c_quad * (x**2)
6
7 print(f"Квадратичная модель:  $y = \{a\_quad:.4f\} + \{b\_quad:.4f\}x + \{c\_quad:.6f\}x^2$ ")
8 print(f"Параметры:  $a = \{a\_quad:.4f\}$ ,  $b = \{b\_quad:.4f\}$ ,  $c = \{c\_quad:.6f\}$ ")
9
```

Таблица 2. Листинг 2: Квадратичная регрессия

```
1 import numpy as np
2
3 # Степенная регрессия:  $y = a * x^b \Rightarrow \ln(y) = \ln(a) + b * \ln(x)$ 
4 b_pow, ln_a_pow = np.polyfit(np.log(x), np.log(y), 1)
5 a_pow = np.exp(ln_a_pow)
6 y_pred_pow = a_pow * (x**b_pow)
7
8 print(f"Степенная модель:  $y = \{a\_pow:.4f\} * x^{\{b\_pow:.4f\}}$ ")
9 print(f"Параметры:  $\ln(a) = \{ln\_a\_pow:.4f\}$ ,  $a = \{a\_pow:.4f\}$ ,  $b = \{b\_pow:.4f\}$ ")
10
```

Таблица 3. Листинг 3: Степенная регрессия

```

1 import numpy as np
2 import scipy.stats as stats
3
4 # Расчет метрик качества моделей (R^2, RMSE, Средняя ошибка аппроксимации)
5 tss = np.sum((y - np.mean(y))**2)
6
7 def calc_metrics(y_pred):
8     rss = np.sum((y - y_pred)**2)
9     r2 = 1 - rss / tss
10    rmse = np.sqrt(rss / n)
11    mask = y != 0
12    a_err = np.mean(np.abs((y[mask] - y_pred[mask]) / y[mask])) * 100
13    return rss, r2, rmse, a_err
14
15 # Вычисляем метрики для всех моделей
16 rss_lin, r2_lin, rmse_lin, a_lin_err = calc_metrics(y_pred_lin)
17 rss_quad, r2_quad, rmse_quad, a_quad_err = calc_metrics(y_pred_quad)
18 rss_pow, r2_pow, rmse_pow, a_pow_err = calc_metrics(y_pred_pow)
19
20 print("Сравнение моделей:")
21 print(f"Линейная:      R² = {r2_lin:.4f}, RMSE = {rmse_lin:.4f}, Ошибка A = {a_lin_err:.2f}%")
22 print(f"Квадратичная:  R² = {r2_quad:.4f}, RMSE = {rmse_quad:.4f}, Ошибка A = {a_quad_err:.2f}%")
23 print(f"Степенная:      R² = {r2_pow:.4f}, RMSE = {rmse_pow:.4f}, Ошибка A = {a_pow_err:.2f}%")
24
25 # Статистический анализ линейной модели
26 mean_x = np.mean(x)
27 S_xx = np.sum((x - mean_x)**2)
28 s2 = rss_lin / (n - 2)
29 s = np.sqrt(s2)
30
31 se_b = s / np.sqrt(S_xx)
32 se_a = s * np.sqrt(1/n + (mean_x**2) / S_xx)
33
34 t_crit = stats.t.ppf(0.975, n - 2)
35 ci_a = (a_lin - t_crit * se_a, a_lin + t_crit * se_a)
36 ci_b = (b_lin - t_crit * se_b, b_lin + t_crit * se_b)
37 t_stat_b = b_lin / se_b
38
39 print("\nСтатистика линейной модели:")
40 print(f"RSS = {rss_lin:.4f}")
41 print(f"Дисперсия (s²) = {s2:.4f}, s = {s:.4f}")
42 print(f"Дов. интервал a: ({ci_a[0]:.2f}, {ci_a[1]:.2f})")
43 print(f"Дов. интервал b: ({ci_b[0]:.4f}, {ci_b[1]:.4f})")
44 print(f"t-набл (для b) = {t_stat_b:.4f}, t-крит = {t_crit:.4f}")
45

```

Таблица 4. Листинг 4: Расчет метрик и ошибок