

Лабораторная работа 6

Домашнее задание, блок 3 (ДЗ3.1)

Отбор значимых признаков: градиентный бустинг + UFSACO

1 Постановка задачи

Согласно ДЗ3.1, мы воспроизводим пайплайн из `UFSACO.ipynb` на собственном наборе данных. Для задачи регрессии нам необходимо:

1. с помощью градиентного бустинга (используем как чёрный ящик) определить значимые признаки для моделирования целевого;
2. с помощью метода муравьиной колонии (UFSACO — unsupervised feature selection) отобрать признаки без использования целевого;
3. обеспечить, чтобы пересечение двух множеств признаков было не меньше четырёх элементов; при необходимости варьировать гиперпараметры АСО.

Формально: пусть $\mathcal{F} = \{f_1, \dots, f_d\}$ — полное множество признаков, y — целевой признак. Каждый метод возвращает подмножество

$$\mathcal{S}_{\text{GB}} \subseteq \mathcal{F}, \quad \mathcal{S}_{\text{ACO}} \subseteq \mathcal{F}, \quad |\mathcal{S}_{\text{GB}}| = |\mathcal{S}_{\text{ACO}}| = k,$$

где k — число отбираемых признаков; требуется

$$|\mathcal{S}_{\text{GB}} \cap \mathcal{S}_{\text{ACO}}| \geq 4, \quad 7 \leq k \leq \lfloor d/2 \rfloor.$$

Здесь d — общее число признаков ($d = 24$ в нашем случае), $\lfloor \cdot \rfloor$ — целая часть.

2 Описание датасета

Источник: «Car Price Prediction Multiple Linear Regression», Kaggle (kaggle.com/datasets), датасет компании Geely Auto, опубликован в 2019 г.

Предметная область. Китайская автомобильная компания Geely Auto планирует выход на рынок США и хочет понять, какие конструктивные и потребительские характеристики автомобилей определяют их цену в американском сегменте. Консалтинговое агентство собрало срез по 205 моделям автомобилей различных производителей. Целевой признак — розничная цена в долларах.

Размер. $n = 205$ объектов, $d = 24$ признака + целевой `price` (всего 25 числовых столбцов после очистки).

Целевой признак. В качестве целевого мы выбрали $y = \text{price}$ — розничную цену автомобиля в долларах США. Это вещественный признак, диапазон значений \$5118–45400, среднее $\bar{y} \approx 13277$, стандартное отклонение $\sigma_y \approx 7989$. Выбор обусловлен постановкой исходной задачи на Kaggle (предсказание цены автомобиля на американском рынке для

компании Geely Auto) — именно цена является той переменной, факторы влияния на которую мы хотим понять, что точно соответствует типу задачи в ДЗ (*регрессия*).

Признаки (после предобработки, см. раздел 2.1):

- *Идентификация*: `carbrand` (марка авто, 22 уникальных значения, label-encoded).
- *Категориальные характеристики кузова и трансмиссии*: `fueltype`, `aspiration`, `doornumber`, `carbody`, `drivewheel`, `enginelocation`, `enginetype`, `fuelsystem` — закодированы целочисленно.
- *Геометрия*: `wheelbase`, `carlength`, `carwidth`, `carheight`, `curbweight`.
- *Силовая установка*: `cylindernumber`, `enginesize`, `boreratio`, `stroke`, `compressionratio`, `horsepower`, `peakrpm`.
- *Топливная экономичность*: `citympg`, `highwaympg`.
- *Рейтинг страхового риска*: `symboling`.
- *Целевой*: `price` (диапазон \$5118–45400).

Пропусков и дубликатов в данных нет.

2.1 Предобработка

Исходный файл `CarPrice_Assignment.xls` (фактически CSV с расширением `.xls`) приведён к чисто числовой матрице $X \in \mathbb{R}^{n \times d}$:

1. удалили служебный `car_ID`;
2. из `CarName` извлекли только марку (`carbrand`); устранили опечатки в названиях марок (`maxda`→`mazda`, `porcshce`→`porsche`, `toyouta`→`toyota`, `vokswagen/vw`→`volkswagen`);
3. словесные числа в `doornumber` и `cylindernumber` (`two`, `four`, ...) перевели в целые;
4. к восьми категориальным признакам применили label-encoding (целые от 0 до $k-1$); `one-hot` не использовали, чтобы остаться в рамках $d = 24$ признаков и сохранить верхнюю границу отбора $\lfloor 24/2 \rfloor = 12$.

Результат сохранили в `CarPrice_clean.csv`.

Каждый признак f_j затем приводится к диапазону $[0, 1]$ преобразованием Min–Max:

$$\tilde{x}_{ij} = \frac{x_{ij} - \min_i x_{ij}}{\max_i x_{ij} - \min_i x_{ij}}, \quad (1)$$

где x_{ij} — значение признака f_j у i -го объекта, $\tilde{x}_{ij}$ — его масштабированный аналог.

2.2 Краткий разведочный анализ

Линейная зависимость каждого признака с целевым оценена через выборочную корреляцию Пирсона:

$$r(f_j, y) = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}, \quad (2)$$

где n — число объектов, x_{ij} — значение j -го признака у i -го объекта, y_i — значение целевого, $\bar{x}_j$ и $\bar{y}$ — их средние.

Десять наибольших по модулю корреляций с целевым:

Признак	r с price
enginesize	+0.874
curbweight	+0.835
horsepower	+0.808
carwidth	+0.759
cylindernumber	+0.718
highwaympg	-0.698
citympg	-0.686
carlength	+0.683
drivewheel	+0.578
wheelbase	+0.578

Видим, что доминируют «размерные» признаки (геометрия + масса + мощность двигателя), сильно скоррелированные между собой ($|r| > 0.7$). Этот факт критически важен — он определяет поведение UFSACO ниже. Расход топлива `highwaympg/citympg` коррелирует с ценой отрицательно (чем больше миль на галлон, тем меньше/легче машина, тем дешевле).

Гистограммы распределений сохранены в `hist_hw3.png`, тепловая карта корреляций — в `corr_heatmap_hw3.png`.

3 Метод 1: Gradient Boosting

3.1 Модель

Используется `sklearn.ensemble.GradientBoostingRegressor`. Модель строит аддитивную композицию из M регрессионных деревьев h_m :

$$\hat{F}_M(\mathbf{x}) = F_0 + \nu \sum_{m=1}^M h_m(\mathbf{x}), \quad (3)$$

где $\mathbf{x}$ — вектор признаков объекта, F_0 — начальное предсказание (среднее по y), $\nu \in (0, 1]$ — темп обучения (learning rate), M — число деревьев, h_m — m -е дерево, обучаемое на градиенте функции потерь от предсказаний предыдущей композиции $\hat{F}_{m-1}$.

В качестве функции потерь используется квадратичная:

$$L(y, \hat{F}) = \frac{1}{2}(y - \hat{F})^2, \quad (4)$$

тогда антиградиент совпадает с остатком $y - \hat{F}$, и на каждой итерации дерево h_m приближает именно остаток предыдущей модели.

3.2 Гиперпараметры

<code>n_estimators</code> (M)	300
<code>max_depth</code>	4
<code>min_samples_split</code>	10
<code>learning_rate</code> (ν)	0.01
<code>random_state</code>	42

3.3 Значимость признаков

Для каждого признака f_j значимость определяется как нормированная сумма уменьшений функции потерь во всех узлах всех деревьев, где этот признак использован для расщепления:

$$I(f_j) = \frac{1}{M} \sum_{m=1}^M \sum_{t \in \mathcal{T}_m^{(j)}} \omega_t \cdot \Delta L_t, \quad (5)$$

где $\mathcal{T}_m^{(j)}$ — множество узлов m -го дерева, где расщепление сделано по признаку f_j , $\omega_t = n_t/n$ — доля объектов, попавших в узел t , ΔL_t — уменьшение функции потерь в этом узле, n_t — размер выборки узла, n — общий размер обучающей выборки.

После обучения качество на обучающей выборке:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 0.9813,$$

где $\hat{y}_i$ — предсказание модели для i -го объекта.

Сортируем $I(f_j)$ по убыванию и берём top- k при $k = 12$ (см. раздел 5.1):

Ранг	Признак
1	enginesize
2	curbweight
3	highwaympg
4	horsepower
5	carlength
6	carwidth
7	carbrand
8	wheelbase
9	stroke
10	compressionratio
11	peakrpm
12	fuelsystem

См. также `gb_importance_hw3.png`.

4 Метод 2: UFSACO (муравьиная колония)

4.1 Идея

Используется реализация из `UFSACO.ipynb` без изменений. Алгоритм *unsupervised*: целевой признак не участвует в построении графа.

Признаки рассматриваются как вершины полного неориентированного графа $G = (\mathcal{F}, E)$. Каждому ребру (i, j) присваивается вес, равный косинусной близости векторов признаков:

$$s(f_i, f_j) = \frac{\langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle}{\|\mathbf{x}^{(i)}\| \cdot \|\mathbf{x}^{(j)}\|}, \quad (6)$$

где $\mathbf{x}^{(i)} \in \mathbb{R}^n$ — столбец масштабированной матрицы признаков, соответствующий признаку f_i , $\langle \cdot, \cdot \rangle$ — скалярное произведение, $\|\cdot\|$ — евклидова норма. Высокое $s(f_i, f_j)$ означает высокую избыточность этой пары.

Каждой вершине j соответствует уровень феромона $\tau_j \geq 0$, изначально $\tau_j = \tau_0$.

4.2 Шаг муравья

Если k -й муравей находится в вершине i и V_k — множество уже посещённых им вершин, то «желательность» следующего перехода в вершину $j \in \mathcal{F} \setminus (V_k \cup \{i\})$:

$$\eta_{ij} = \frac{\tau_j}{(s(f_i, f_j) + \varepsilon)^\alpha}, \quad (7)$$

где τ_j — текущий уровень феромона на вершине j , $s(f_i, f_j)$ — косинусная близость (6), $\alpha > 0$ — параметр относительной важности «некоррелированности», ε — малая константа для численной устойчивости. Чем меньше $s(f_i, f_j)$ и больше τ_j , тем выгоднее переход.

С вероятностью $q_0 \in [0, 1]$ (EXPLOITATION_PROB) муравей переходит детерминированно (exploitation):

$$j^* = \arg \max_{j \notin V_k \cup \{i\}} \eta_{ij}, \quad (8)$$

иначе (exploration) — стохастически с вероятностями, пропорциональными η_{ij} :

$$P(j \mid i, V_k) = \frac{\eta_{ij}}{\sum_{\ell \notin V_k \cup \{i\}} \eta_{i\ell}}. \quad (9)$$

4.3 Обновление феромона

После того как все N_{ants} муравьёв сделали по N_{steps} шагов внутри одной эпохи, для каждой вершины j известно количество визитов v_j . Феромон обновляется по правилу:

$$\tau_j \leftarrow (1 - \rho) \tau_j + \frac{v_j}{\sum_{\ell} v_{\ell}}, \quad (10)$$

где $\rho \in (0, 1]$ — коэффициент испарения (RO), v_j — число визитов вершины j за текущую эпоху, $\sum_{\ell} v_{\ell}$ — общее число визитов (нормирует прирост).

4.4 Финальный отбор

Внешний цикл повторяется NC_{max} эпох. По окончании ранжируем вершины по τ_j и берём k с наибольшими значениями:

$$\mathcal{S}_{\text{ACO}} = \text{Top}_k\{\tau_1, \dots, \tau_d\}. \quad (11)$$

4.5 Замечание о масштабировании

В ноутбуке применён `MinMaxScaler` (1), но в нашем датасете несколько закодированных категориальных признаков (`enginolocation`, `aspiration`, `doornumber`) почти константы — одно значение встречается у $\geq 90\%$ объектов. После Min-Max их вектор $\mathbf{x}^{(j)}$ близок к нулевому, норма $\|\mathbf{x}^{(j)}\| \rightarrow 0$, и косинусная близость $s(f_i, f_j)$ становится численно неустойчивой — такие признаки получают завышенные η_{ij} и захватывают весь `top-k`.

Чтобы устранить эту патологию, мы дополнительно центрируем матрицу признаков преобразованием Z-score:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j}, \quad (12)$$

где $\bar{x}_j$ и σ_j — выборочное среднее и стандартное отклонение j -го признака. На центрированных векторах формула (6) переходит в коэффициент корреляции Пирсона — ту же меру (2), что используется для EDA. Сам алгоритм UFSACO при этом остаётся без изменений.

4.6 Гиперпараметры

Дефолтные значения из ноутбука дали слишком малое пересечение с GB (см. раздел 5.2).
Финальные значения:

Обозначение	Параметр	Значение
$NC_{\max}$	число эпох (NC_MAX)	50
N_{steps}	шагов в эпохе (N_STEPS)	10
N_{ants}	число муравьёв (N_ANTS)	25
τ_0	начальный феромон (INIT_PHER.)	0.2
ρ	коэф. испарения (R0)	0.1
q_0	вероятность exploitation	0.7
α	вес «некоррелированности»	0.2
k	число отбираемых признаков	12

4.7 Устойчивость: 5 запусков

Чтобы оценить разброс, мы запустили алгоритм 5 раз; финальный список — 12 признаков, чаще всего попадавших в top-12 (по частоте появлений). Если обозначить c_j — число запусков, в которых признак f_j попал в top- k , то:

$$\mathcal{S}_{\text{ACO}}^{\text{final}} = \text{Top}_k\{c_1, \dots, c_d\}. \quad (13)$$

Итоговый top-12 UFSACO: enginetype, stroke, cylindernumber, doornumber, carbody, peakrpm, symboling, boreratio, aspiration, highwaympg, horsepower, compressionratio.

5 Сравнение и пересечение

Признак	GB	UFSACO
aspiration		✓
boreratio		✓
carbody		✓
carbrand	✓	
carlength	✓	
carwidth	✓	
compressionratio	✓	✓
curbweight	✓	
cylindernumber		✓
doornumber		✓
enginesize	✓	
enginetype		✓
fuelsystem	✓	
highwaympg	✓	✓
horsepower	✓	✓
peakrpm	✓	✓
stroke	✓	✓
symboling		✓
wheelbase	✓	

Пересечение:

$$\mathcal{S}_{\text{GB}} \cap \mathcal{S}_{\text{ACO}} = \{\text{compressionratio}, \text{highwaympg}, \text{horsepower}, \text{peakrpm}, \text{stroke}\}.$$

Мощность пересечения $|\mathcal{S}_{\text{GB}} \cap \mathcal{S}_{\text{ACO}}| = 5 \geq 4$ — требование выполнено.

Дополнительно мы оценили «согласованность» двух методов через коэффициент Жаккара:

$$J(\mathcal{S}_{\text{GB}}, \mathcal{S}_{\text{ACO}}) = \frac{|\mathcal{S}_{\text{GB}} \cap \mathcal{S}_{\text{ACO}}|}{|\mathcal{S}_{\text{GB}} \cup \mathcal{S}_{\text{ACO}}|} = \frac{5}{19} \approx 0.263, \quad (14)$$

где $|\cdot|$ — мощность множества. Значение $J \in [0, 1]$; $J = 1$ означает полное совпадение, $J = 0$ — непересечение.

5.1 Выбор k

По правилу ЛР, $7 \leq k \leq \lfloor 24/2 \rfloor = 12$. Эксперименты при $k = 7, 10, 12$:

k	$ \mathcal{S}_{\text{GB}} \cap \mathcal{S}_{\text{ACO}} $	комментарий
7	0–2	пересечение мало даже при тюнинге
10	2	лучше, но не до 4
12	5	требование выполнено

5.2 Подбор гиперпараметров АСО

С дефолтами ноутбука ($\text{NC}_{\text{max}} = 3$, $N_{\text{steps}} = 4$, $N_{\text{ants}} = 5$, $\alpha = 1$, `MinMaxScaler`) при $k = 7$ пересечение составило 2. Причина в характере данных: GB-top — единый кластер сильно скоррелированных «размерных» признаков (`engine size`, `curbweight`, `carlength`, `carwidth`, `horsepower`), а UFSACO по дизайну, согласно формуле (7), штрафует за высокое $s(f_i, f_j)$ — то есть выбирает по одному представителю каждого кластера. Чтобы поднять перекрытие, мы:

1. увеличили k до 12 (тогда GB захватывает не только «размерный» кластер, а UFSACO — больше представителей других кластеров);
2. понизили α с 1.0 до 0.2; согласно (7), при $\alpha \rightarrow 0$ знаменатель $\rightarrow 1$ и штраф за сходство ослабевает, что позволяет АСО выбирать несколько членов одного кластера;
3. увеличили число эпох (NC_{max} : 3→50), шагов (N_{steps} : 4→10) и муравьёв (N_{ants} : 5→25) для стабилизации феромона τ в (10);
4. понизили испарение ρ с 0.2 до 0.1, чтобы накопленный опыт переходов не «вымылся» слишком быстро (множитель $1 - \rho$ в (10)).

6 Интерпретация результатов

Пять общих признаков логично интерпретируются:

- `horsepower` — мощность; ключевой драйвер цены, оба метода согласны.
- `highwaympg` — экономичность; обратно связана с мощностью, но не полностью — UFSACO видит в ней самостоятельный кластер.
- `peakrpm` — характеристика оборотистости двигателя, слабо коррелирует с размерным кластером.

- `stroke` — ход поршня, конструктивная характеристика двигателя, малая корреляция со всем остальным.
- `compressionratio` — степень сжатия, аналогично — отдельный кластер.

Признаки «размерного» кластера (`enginesize`, `curbweight`, `carlength`, `carwidth`, `carbrand`, `wheelbase`) попали только в GB-top: АСО выбирает максимум одного представителя такого кластера и переключается на менее коррелированные признаки. Это нормальное и предсказуемое поведение unsupervised-метода — его задача согласно (7) найти *разнообразное* подпространство, а не максимально предсказательное.

7 Воспроизводимость

Код: `ufsaco_hw3.py` (один файл, запуск `python ufsaco_hw3.py`).

Зависимости: `numpy`, `pandas`, `matplotlib`, `seaborn`, `scikit-learn`.


Артефакты после запуска:

- `CarPrice_clean.csv` — предобработанный датасет;
- `eda_describe_hw3.csv` — описательные статистики;
- `hist_hw3.png` — гистограммы;
- `corr_with_price_hw3.csv`, `corr_heatmap_hw3.png` — корреляции;
- `gb_importance_hw3.png` — важности GB;
- `sim_top10_hw3.csv`, `sim_bot10_hw3.csv` — самые похожие/различные пары признаков по cos-similarity;
- `results_hw3.json` — финальные результаты в машиночитаемом виде.

8 Выводы

1. Датасет `CarPrice` (205×24) полностью удовлетворяет требованиям ДЗ к составу, размеру и году публикации.
2. Градиентный бустинг согласно (3) достигает $R^2 = 0.98$ на обучении и ожидаемо выделяет «размерный» кластер как наиболее информативный для прогноза цены.
3. UFSACO ведёт себя как unsupervised-метод: согласно формуле (7) выбирает *взаимно различные* признаки, а не самые предсказательные. На датасете с одним доминирующим скоррелированным кластером это естественно расходится с GB.
4. После настройки гиперпараметров и выбора $k = 12$ мы получили пересечение из 5 признаков (`compressionratio`, `highwaympg`, `horsepower`, `peakrpm`, `stroke`), что превосходит порог в 4 признака; коэффициент Жаккара $J \approx 0.263$.

А Топ-12 GB по убыванию важности



В Корреляционная матрица

