

## Отбор значимых признаков. Метод UFSACO

Рассмотрим пример на данных домена «Норильского никеля».

Есть датасет, 16 признаков, 27856 объектов, многомерный временной ряд (равномерный шаг 15 минут), есть пропуски в данных. Целевой признак – TailCU – содержание меди в «хвостах» (по техпроцессу требуется, чтоб содержание было как можно меньше). Для моделирования этого вещественного признака используются ещё 15 вещественных. Процесс: вещество проходит последовательно через каскад из 8 бочек, расположенных друг за другом: на каждой из них частицы руды могут быть выделены в пену (пенная флотация), либо перейти в следующую бочку. Рабочий объём в бочках, как следствие, скорость съёма пены, объём пены, можно регулировать через уставку уровня. Для формирования пены подаётся воздух, а также вещество в бочке («пульпа») перемешивается с помощью импеллера, ток двигателя импеллера учитывается как величина для оценки плотности (насколько тяжело перемешивать). Добавление реагентов не учитывается – для простоты.

Признаки:

|                                                                |                                                         |
|----------------------------------------------------------------|---------------------------------------------------------|
| in_CU, in_FE, in_NI,                                           | Содержание меди, железа и никеля на входе каскада бочек |
| Speed_2, Speed_4, Speed_6, Speed_8,                            | Скорость пеносъёма на бочках (номер бочки)              |
| Lvl 2 setpoint, Lvl 4 setpoint, Lvl 6 setpoint, Lvl 8 setpoint | Уставка уровня на бочках (номер бочки)                  |
| Air 3, Air 4                                                   | Расход воздуха к бочке (номер бочки)                    |
| Tok 3, Tok 4                                                   | Ток двигателя импеллера (номер бочки)                   |

Первичный («разведывательный») анализ данных (EDA, Exploratory Data Analysis) начинается обычно с загрузки датасета как объекта DataFrame библиотеки pandas и вызова методов класса DataFrame: head(), info(), describe(), hist().

Обратите внимание, как изменятся выборочные распределения для признаков, если применить фильтрацию – например, указать границы, вне которых данные не представляют интереса (см «Уберем строки с нетипичными значениями»).

Преобразование данных (нормирование) – MinMaxScaler – не является обязательным в данной задаче, но не помешает (детали в дисциплине «Системы искусственного интеллекта»).

Первый метод, который применим для оценки значимости признаков, будет градиентный бустинг. Зададим гиперпараметры его реализации sklearn.ensemble.GradientBoostingRegressor ("n\_estimators": 300, "max\_depth": 4, "min\_samples\_split": 10, "learning\_rate": 0.01). Можно рассматривать бустинг как черный ящик (детали будут в следующем семестре) – он ответит, какие признаки наиболее полезны для моделирования признака TailCU (выберем 7 наиболее важных: N\_FEATURES = 7).

Особенность бустинга заключается в том, что важность признаков вычисляется на его итерациях, потому по завершении метода можно запросить эту информацию (model\_base\_full.feature\_importances\_). Визуализация показывает не только список важных признаков, но и меру важности каждого (score) для этих признаков («больше значит лучше»).

Метод муравьиной колонии будет отбирать признаки (N\_END\_FEATURES = 7), не используя таргет, хотя есть модификации с учётом конкретного целевого признака.

Для метода муравьиной колонии аналогично задаём уже его гиперпараметры.

Обратите внимание, что если алгоритм запустить независимо 5 раз, то результаты будут отличаться. Однако устойчивость проявляется в том, что `in_NI` и `Speed_6` присутствуют во всех.

Далее рассмотрим пары признаков: упорядочим по возрастанию меры схожести и по убыванию. В частности, наиболее похожими оказались `Air 3` и `Air 4`, а также `Tok 3` и `Tok 4`. Нас же интересуют наименее похожие: таковыми являются `in_NI` и `Speed_6`.

Последний шаг – сравним результаты метода муравьиной колонии и градиентного бустинга, найдём пересечение множеств найденных признаков: чем больше признаков, которые работают на моделирование таргета (метод градиентного бустинга), окажутся значимыми и/или менее похожими в масштабах всего датасета (метод муравьиной колонии), тем лучше.